

۱ گام ۲ - ماتریس تشابه: تقارن (پرسش ۱-الف)

هر پیکسل را یک گره در نظر می‌گیریم و وزن یال میان دو پیکسل i و j را طبق رابطه‌ی (۱) این‌طور تعریف می‌کنیم:

$$W_{ij} = \begin{cases} \exp\left(\frac{-\|F_i - F_j\|_2^2}{\sigma_I^2}\right) \cdot \exp\left(\frac{-\|X_i - X_j\|_2^2}{\sigma_X^2}\right), & \|X_i - X_j\|_2 < r, \\ 0, & \text{در غیر این صورت,} \end{cases}$$

و طبق قرارداد $W_{ii} = 0$ (هیچ گره ای با خودش یال ندارد).

ادعا. ماتریس W دقیقاً متقارن است؛ یعنی برای هر زوج پیکسل i و j همواره $W_{ij} = W_{ji}$ برقرار است.

بخش (الف): اثبات تحلیلی تقارن ماتریس W . برای اثبات اینکه ماتریس W دقیقاً متقارن است، باید نشان دهیم که برای هر زوج پیکسل i و j ، رابطه‌ی $W_{ij} = W_{ji}$ همواره برقرار است. فرمول وزن برای حالت $\|X_i - X_j\|_2 < r$ به شکل زیر است:

$$W_{ij} = \exp\left(\frac{-\|F_i - F_j\|_2^2}{\sigma_I^2}\right) \cdot \exp\left(\frac{-\|X_i - X_j\|_2^2}{\sigma_X^2}\right).$$

اثبات. می‌دانیم که نرم-۲ (فاصله‌ی اقلیدسی) دارای خاصیت همگنی مطلق است؛ یعنی برای هر بردار V و عدد ثابت c داریم $\|cV\| = |c| \|V\|$. اگر $c = -1$ باشد:

$$\|F_i - F_j\|_2 = \|(-1)(F_j - F_i)\|_2 = |-1| \cdot \|F_j - F_i\|_2 = \|F_j - F_i\|_2.$$

با به توان رساندن طرفین، نتیجه می‌گیریم که فاصله‌ی روشنایی دو پیکسل از هر طرف که محاسبه شود یکسان است:

$$\|F_i - F_j\|_2^2 = \|F_j - F_i\|_2^2.$$

$$\|X_i - X_j\|_2^2 = \|X_j - X_i\|_2^2.$$

شرط فاصله‌ی مکانی، یعنی $\|X_i - X_j\|_2 < r$ ، نیز با توجه به اثبات بالا دقیقاً معادل شرط $\|X_j - X_i\|_2 < r$ است. اکنون اگر فرمول W_{ji} را بنویسیم:

$$W_{ji} = \exp\left(\frac{-\|F_j - F_i\|_2^2}{\sigma_I^2}\right) \cdot \exp\left(\frac{-\|X_j - X_i\|_2^2}{\sigma_X^2}\right),$$

با جایگذاری تساوی‌های به‌دست‌آمده از گام اول، به‌وضوح به معادله‌ی اصلی می‌رسیم:

$$W_{ji} = \exp\left(-\frac{\|F_i - F_j\|_2^2}{\sigma_I^2}\right) \cdot \exp\left(-\frac{\|X_i - X_j\|_2^2}{\sigma_X^2}\right) = W_{ij}.$$

چون برای حالت $\|X_i - X_j\|_2 \geq r$ نیز مقدار هر دو درایه‌ی W_{ji} و W_{ij} برابر صفر تعریف شده است، پس در تمامی حالات $W_{ij} = W_{ji}$ برقرار بوده و ماتریس W ذاتاً یک ماتریس متقارن است.

تأیید عددی (پرسش ۱-ب). در کد مقدار $\|W - W^\top\|_F$ را محاسبه کردیم و برابر 0 شد؛ پس تقارن به‌صورت عددی هم تأیید می‌شود.

مقادیر انتخابی. $\sigma_X = 4$ ، $\sigma_I = 0.1$ و $r = 5$ (برحسب پیکسل). این سه پارامتر تعیین می‌کنند که «شبه‌ت» بین دو پیکسل چقدر سخت‌گیرانه سنجیده شود:

- σ_I هرچه بزرگ‌تر باشد، اختلاف روشنایی بیشتری تحمل می‌شود، وزن‌ها یکنواخت‌تر می‌شوند و مرزها نرم‌تر درمی‌آیند؛ اگر خیلی کوچک باشد فقط پیکسل‌های تقریباً هم‌رنگ به هم وصل می‌مانند و قطعه‌بندی به نویز حساس می‌شود.
- σ_X بزرگ‌تر شدنش پیکسل‌های دورتر را هم به هم پیوند می‌دهد و نواحی گسترده‌تری می‌سازد؛ کوچک‌بودنش گراف را محلی‌تر و قطعه‌ها را ریزتر می‌کند.
- r شعاع همسایگی است؛ یال فقط بین پیکسل‌هایی با فاصله‌ی کمتر از r برقرار می‌شود؛ این برش، ماتریس W را تُنک نگه می‌دارد و هزینه‌ی محاسبات را کم می‌کند.

۲ گام ۳ – لاپلاسین نرمال شده (پرسش ۲)

درجه‌ی هر گره $d_i = \sum_j W_{ij}$ ، ماتریس درجه $D = \text{diag}(d_1, \dots, d_n)$ ، و

$$L_{\text{sym}} = D^{-1/2}(D - W)D^{-1/2} = I - D^{-1/2}WD^{-1/2}.$$

۱.۲ الف) تقارن L_{sym}

اثبات. از فرم $L_{\text{sym}} = I - D^{-1/2}WD^{-1/2}$ شروع می‌کنیم و برای گرفتن ترانهاده از دو ویژگی جبر خطی استفاده می‌کنیم: (۱) $(A - B)^T = A^T - B^T$ ، و (۲) $(ABC)^T = C^T B^T A^T$. بنابراین

$$L_{\text{sym}}^T = (I - D^{-1/2}WD^{-1/2})^T = I^T - (D^{-1/2}WD^{-1/2})^T.$$

- ماتریس همانی متقارن است، پس $I^T = I$.
- چون D قطری است، $D^{-1/2}$ هم قطری و در نتیجه متقارن است: $(D^{-1/2})^T = D^{-1/2}$.
- در پرسش ۱ ثابت کردیم که ماتریس مجاورت متقارن است، پس $W^T = W$.

$$(D^{-1/2}WD^{-1/2})^T = (D^{-1/2})^T W^T (D^{-1/2})^T = D^{-1/2}WD^{-1/2}.$$

پس در نهایت

$$L_{\text{sym}}^T = I - D^{-1/2}WD^{-1/2} = L_{\text{sym}},$$

و به صورت تحلیلی ثابت شد که L_{sym} ماتریسی متقارن است.

۲.۲ ب) حقیقی بودن طیف و قرارگیری در بازه‌ی $[0, 2]$

تحلیل تئوری. در بخش (الف) ثابت کردیم که L_{sym} متقارن است. «اگر A ماتریسی حقیقی و متقارن باشد، همه‌ی مقادیر ویژه‌اش حقیقی‌اند.» در نظریه‌ی گراف طیفی نشان داده می‌شود که لاپلاسین نرمال شده نیمه‌معین مثبت است (یعنی $\lambda_i \geq 0$) و بزرگ‌ترین مقدار ویژه‌اش همواره $\lambda_{\max} \leq 2$ است.

برای اثبات دقیق بازه، کافی است نشان دهیم هم L_{sym} و هم $2I - L_{\text{sym}}$ نیمه‌معین مثبت‌اند؛ اولی گران پایین ۰ و دومی گران بالای ۲ را تضمین می‌کند.

اثبات. قرار می‌دهیم $y = D^{-1/2}x$. آنگاه

$$\begin{aligned} x^T L_{\text{sym}} x &= x^T D^{-1/2}(D - W)D^{-1/2}x = y^T (D - W)y \\ &= \frac{1}{2} \sum_{i,j} W_{ij} (y_i - y_j)^2 \geq 0, \end{aligned}$$

این یعنی $L_{\text{sym}} \succeq 0$ و بنابراین همه‌ی مقادیر ویژه ≥ 0 هستند. حالا به سراغ کران بالا می‌رویم:

$$2I - L_{\text{sym}} = I + D^{-1/2}WD^{-1/2} = D^{-1/2}(D + W)D^{-1/2},$$

و مشابه بالا

$$x^T(2I - L_{\text{sym}})x = y^T(D + W)y = \frac{1}{2} \sum_{i,j} W_{ij} (y_i + y_j)^2 \geq 0,$$

پس $2I - L_{\text{sym}} \succeq 0$ و همه‌ی مقادیر ویژه ≤ 2 هستند. این دو کران کنار هم نشان می‌دهند که کل طیف داخل $[0, 2]$ جا می‌گیرد.

تأیید عددی. در کد طیف را محاسبه کردیم: کوچک‌ترین مقدار ویژه حدود -2×10^{-15} (عملاً صفر) و بزرگ‌ترین حدود 1.08 به دست آمد، که با بازه‌ی $[0, 2]$ سازگار است.

۳.۲ ج) کوچک‌ترین مقدار ویژه‌ی صفر و بردار ویژه‌ی بدیهی

ادعا. $\lambda = 0$ مقدار ویژه‌ی L_{sym} است و بردار ویژه‌ی متناظرش $v_0 = D^{1/2}\mathbf{1} = (\sqrt{d_1}, \dots, \sqrt{d_n})^T$ است.

اثبات. برای اثبات اینکه $v_0 = D^{1/2}\mathbf{1}$ بردار ویژه با مقدار ویژه‌ی $\lambda = 0$ است، باید نشان دهیم $L_{\text{sym}}v_0 = 0 \cdot v_0 = 0$ (بردار 1 همان برداری است که همه‌ی درایه‌هایش 1 است). داریم

$$\begin{aligned} L_{\text{sym}}(D^{1/2}\mathbf{1}) &= (I - D^{-1/2}WD^{-1/2})(D^{1/2}\mathbf{1}) \\ &= D^{1/2}\mathbf{1} - D^{-1/2}W(D^{-1/2}D^{1/2})\mathbf{1} = D^{1/2}\mathbf{1} - D^{-1/2}(W\mathbf{1}). \end{aligned}$$

حالا به تعریف ماتریس درجه دقت کنیم: $d_i = \sum_j W_{ij}$ ؛ یعنی ضرب W در بردار 1 (که معادل جمع‌زدن سطرهای W است) دقیقاً بردار درجه‌ها را می‌دهد: $W\mathbf{1} = D\mathbf{1}$. با جایگذاری:

$$L_{\text{sym}}(D^{1/2}\mathbf{1}) = D^{1/2}\mathbf{1} - D^{-1/2}(D\mathbf{1}) = D^{1/2}\mathbf{1} - D^{1/2}\mathbf{1} = 0.$$

پس $D^{1/2}\mathbf{1}$ بردار ویژه‌ی متناظر با مقدار ویژه‌ی صفر است؛ و چون از قسمت قبل می‌دانیم طیف نامنفی است، همین $\lambda = 0$ کوچک‌ترین مقدار ویژه است.

چرا این بردار ویژه اطلاعاتی برای قطعه‌بندی ندارد؟

بردار ویژه‌ی متناظر با مقدار ویژه‌ی صفر، حالتی را نشان می‌دهد که کل گراف (تصویر) به‌عنوان یک «مجموعه‌ی واحد و پیوسته» در نظر گرفته شده و هیچ برشی

در آن رخ نداده است. چون همه‌ی درایه‌های این بردار متناسب با ریشه‌ی درجه‌ی گره‌ها ($\sqrt{d_i}$) و همگی هم‌علامت‌اند، نمی‌توانند گره‌ها را به دو یا چند دسته‌ی مجزا تفکیک کنند؛ پس برای عمل «قطعه‌بندی» که نیازمند جداسازی است بی‌فایده‌اند و کنار گذاشته می‌شوند.

۴.۲ (د) ارتباط با کیفیت «برش» گراف

ماتریس L_{sym} شکل نرمال‌شده‌ای از ساختار گراف است که هم ارتباطات بین گره‌ها (از طریق W) و هم تراکم محلی هر گره (از طریق D) را در بر می‌گیرد و برای حل تقریبی مسئله‌ی بهینه‌سازی «برش نرمال‌شده» ساخته می‌شود. فرم درجه‌دومش $x^T L_{\text{sym}} x = \frac{1}{2} \sum_{ij} W_{ij} (y_i - y_j)^2$ (با $y = D^{-1/2} x$) هزینه‌ی برش گراف را اندازه می‌گیرد؛ اگر دو پیکسل شبیه و نزدیک برچسب متفاوت بگیرند جریمه می‌شویم. مقادیر ویژه‌ی کوچک این ماتریس نشان‌دهنده‌ی برش‌هایی‌اند که کمترین هزینه (وزن یال‌های قطع‌شده) را نسبت به حجم نواحی جداشده دارند؛ به همین دلیل بردارهای ویژه‌ی متناظر با کوچک‌ترین مقادیر ویژه‌ی ناصفر، بهترین توابع نشانگر برای تفکیک گراف به نواحی متراکم و معنادار با مرزهای ضعیف (قطعه‌بندی بهینه) محسوب می‌شوند.

۳ گام ۴ – روش حذف (پرسش ۳)

فرض کنیم A یک ماتریس متقارن حقیقی $n \times n$ باشد با مقادیر ویژه $\lambda_1, \dots, \lambda_n$ و بردارهای ویژه $X_1, \dots, X_n$ که دو به دو متعامد؛ یعنی $X_1^\top X_1 = 1$ و برای $i \neq j$ داریم $X_j^\top X_i = 0$ و معادله‌ی مقدار ویژه $AX_i = \lambda_i X_i$ برقرار است. ماتریس حذف شده را این‌طور می‌سازیم:

$$B = A - \lambda_1 X_1 X_1^\top.$$

ادعا. بردارهای ویژه B دقیقاً همان بردارهای ویژه A هستند؛ مقدار ویژه X_1 متناظر با X_1 به صفر تبدیل می‌شود و سایر مقادیر ویژه بدون تغییر می‌مانند.

اثبات. اثر B را روی X_1 و روی سایر بردارها جداگانه بررسی می‌کنیم.
بخش اول – اثر B روی X_1 : با پخش کردن X_1 در پرانتز داریم

$$BX_1 = (A - \lambda_1 X_1 X_1^\top) X_1 = AX_1 - \lambda_1 X_1 (X_1^\top X_1).$$

طبق فرض $AX_1 = \lambda_1 X_1$ و چون X_1 یکه است $X_1^\top X_1 = 1$ ؛ پس

$$BX_1 = \lambda_1 X_1 - \lambda_1 X_1 \cdot 1 = 0 = 0 \cdot X_1.$$

یعنی X_1 همچنان بردار ویژه B است، اما با مقدار ویژه 0 ؛ پس λ_1 حذف شده است.

بخش دوم – اثر B روی X_i برای $i \neq 1$: این‌بار چون بردارهای ویژه ماتریس متقارن متعامدند، $X_1^\top X_i = 0$ ؛ پس

$$BX_i = AX_i - \lambda_1 X_1 (X_1^\top X_i) = \lambda_i X_i - \lambda_1 X_1 \cdot 0 = \lambda_i X_i.$$

یعنی X_i دست‌نخورده می‌ماند و همان مقدار ویژه λ_i را حفظ می‌کند. نتیجه اینکه B همان بردارهای ویژه A را دارد و فقط طیفش به $\{0, \lambda_2, \lambda_3, \dots, \lambda_n\}$ تغییر کرده است. بنابراین اگر پیش‌تر $|\lambda_1|$ غالب بود، اکنون λ_2 مقدار ویژه غالب B است و می‌توان روش تکراری را دوباره روی B اجرا کرد.

۴ گام ۴ – تعامد و تکرار حذف (پرسش ۴)

۱.۴ الف) تعامد بردارهای ویژه‌ی ماتریس متقارن

ادعا. اگر A متقارن حقیقی باشد و X_i, X_j بردارهای ویژه‌ی متناظر با مقادیر ویژه‌ی متمایز $\lambda_i \neq \lambda_j$ باشند، آنگاه $X_i \perp X_j$.

اثبات. از معادلات مقدار ویژه شروع می‌کنیم: $AX_i = \lambda_i X_i$ و $AX_j = \lambda_j X_j$. کمیت $X_j^T AX_i$ را به دو روش محاسبه می‌کنیم. از یک سو با استفاده از $AX_i = \lambda_i X_i$:

$$X_j^T AX_i = X_j^T (\lambda_i X_i) = \lambda_i (X_j^T X_i).$$

از سوی دیگر، چون $X_j^T AX_i$ یک اسکالر است، با خودش برابر ترانزپوزیشن است، و با به‌کارگیری تقارن $A^T = A$:

$$X_j^T AX_i = (X_j^T AX_i)^T = X_i^T A^T X_j = X_i^T AX_j = X_i^T (\lambda_j X_j) = \lambda_j (X_j^T X_i),$$

که در گام آخر از خاصیت جابه‌جایی ضرب داخلی، $X_i^T X_j = X_j^T X_i$ ، استفاده شد. حالا این دو عبارت را از هم کم می‌کنیم:

$$(\lambda_i - \lambda_j) (X_j^T X_i) = 0.$$

چون طبق فرض $\lambda_i \neq \lambda_j$ ، پرانتز اول صفر نیست؛ پس الزاماً $X_j^T X_i = 0$ ، یعنی X_i و X_j بر هم عمودند.

۲.۴ ب) چرا تصویرگیری باید در هر تکرار تکرار شود؟

روند گسترش به $z_2, \dots, z_k$. برای پیدا کردن بردار فیدلر (z_2)، متناظر با دومین مقدار ویژه‌ی کوچک لاپلاسی (از «توان معکوس با شیف» استفاده می‌کنیم. اما چون نزدیک‌ترین مقدار ویژه به شیف صفر همان $\lambda_1 = 0$ است، الگوریتم ذاتاً به سمت بردار بدیهی z_1 همگرا می‌شود. برای جلوگیری، در هر مرحله از تکرار بردار به‌دست‌آمده را روی مکمل متعامد z_1 تصویر می‌کنیم (با گرام-اشمیت)؛ این‌طور مؤلفه‌ی z_1 حذف می‌شود و الگوریتم مجبور می‌شود به سمت دومین مقدار ویژه‌ی غالب، یعنی z_2 ، همگرا شود. برای z_3 باید بردار را روی مکمل متعامد هر دو بردار z_1 و z_2 تصویر کنیم و به همین ترتیب تا z_k .

چرا تصویرگیری باید در «هر تکرار» تکرار شود؟ این مستقیماً به خطای گرد کردن ماشین برمی‌گردد. از نظر تئوری اگر بردار اولیه را فقط یک‌بار در ابتدا بر بردارهای حذف‌شده عمود کنیم، این تعامد باید تا پایان حفظ شود؛ اما در حساب ممیز شناور، در هر ضرب ماتریسی روش توانی مقدار بسیار کوچکی از مؤلفه‌ی z_1 (و بردارهای قبلی)

دوباره وارد بردار می‌شود (نشت می‌کند). چون z_1 در «توان معکوس» مقدار ویژه‌ی غالب است، این مؤلفه‌ی ناچیز در تکرارهای بعدی به سرعت رشد می‌کند و بردار را به سمت جواب بدیهی منحرف می‌کند. پس باید در پایان هر تکرار عمل تصویرگیری (متعامدسازی) را دوباره روی مکمل متعامد بردارهای حذف شده انجام دهیم تا این خطای انباشته پاک شود و الگوریتم در مسیر درست بماند؛ در حذف انباشته نیز هر بردار جدید باید بر همه‌ی بردارهای قبلی عمود بماند.

۵ گام ۵ – تجزیه‌ی PLU و تحلیل هزینه (پرسش ۵)

در روش توان معکوس، در هر تکرار باید دستگاه $(\mu I - L_{\text{sym}})x = b$ را حل کنیم. اما ماتریس $(\mu I - L_{\text{sym}})$ در طول همه‌ی تکرارها ثابت می‌ماند و تنها سمت راست b تغییر می‌کند. پس تجزیه‌ی PLU را فقط یک‌بار پیش از حلقه انجام می‌دهیم و در هر تکرار تنها جای‌گذاری پیش‌رو و پس‌رو را تکرار می‌کنیم.

هزینه	عمل
$O(n^3)$	یک‌بار تجزیه‌ی PLU (با محورگیری جزئی)
$O(n^2)$	هر جای‌گذاری پیش‌رو روی L و پس‌رو روی U

با فرض اجرای T تکرار:

$$\underbrace{O(n^3)}_{\text{یک‌بار تجزیه}} + T \cdot \underbrace{O(n^2)}_{\text{جای‌گذاری}} = O(n^3 + T n^2),$$

در حالی که اگر مثل رویکرد بهینه‌نشده در هر تکرار ماتریس را از نو تجزیه کنیم:

$$T \cdot O(n^3) = O(T n^3).$$

یعنی در جمله‌ی غالب تقریباً به اندازه‌ی ضریب T صرفه‌جویی می‌شود؛ رویکرد «یک‌بار تجزیه و T بار جای‌گذاری» به مراتب کم‌هزینه‌تر از تجزیه‌ی مکرر است.


۶ گام ۶ – تحلیل نتایج قطعه‌بندی (پرسش ۶)

بردارهای ویژه‌ی $z_2, \dots, z_k$ را به صورتِ ستون‌های یک ماتریس $n \times (k - 1)$ کنار هم می‌چینیم؛ آن‌گاه هر سطر این ماتریس نقشِ یک «بردارِ ویژگی» برای یک پیکسل را پیدا می‌کند، و با اجرای k -means روی همین سطرها هر پیکسل برچسبِ خودش را می‌گیرد.

• $k = 2$: تنها بردار فیدلر z_2 به کار می‌رود و تصویر به دو ناحیه (پیش‌زمینه/پس‌زمینه) تقسیم می‌شود؛ این برش روی مرزِ شیء می‌نشیند و با درکِ انسانی از «شیء» هم‌خوانی دارد.

• $k = 3, 4$: بردارهای بیشتری (z_3, z_4) وارد می‌شوند و الگوریتم شروع به تفکیکِ جزئیاتِ داخلی اشیاء یا سایه‌ها و بافت‌های مختلفِ پس‌زمینه می‌کند. این نواحی از نظرِ بصری (پیوستگی مکانی و شباهتِ رنگ) همچنان معنادارند، اما ممکن است یک شیء واحدِ انسانی (مثلاً فردی با لباسِ چندرنگ) به دلیلِ تنوعِ طیفِ رنگی به چند خوشه‌ی مجزا خرد شود و از تعریفِ مفهومیِ یکتای «شیء» فاصله بگیرد.

نتیجه. خوشه‌بندی را روی نگاشتِ $y = D^{-1/2}z$ زدیم. وقتی $k = 2$ بود، خروجی دقیقاً همان چیزی شد که انتظار داشتیم: شیء تمیز از پس‌زمینه جدا شد. اما تا k را به 3 و 4 رساندیم، به جای اینکه جزئیاتِ بیشتری از خودِ شیء بیرون بیاید، بیشترِ پس‌زمینه بود که به تکه‌های کوچک‌تر تقسیم می‌شد.



تصویر اصلی در کنار نتیجه‌ی قطعه‌بندی برای $k = 2, 3, 4$.

۷ پرسش ۷ – الگوریتم لانتساش

۱.۷ ایده‌ی کلی

الگوریتم لانتساش در واقع نسخه‌ی بهینه‌شده‌ای از «الگوریتم آرنولدی» برای ماتریس‌های متقارن است و بر پایه‌ی مفهوم زیرفضای کرایلف بنا شده است. ایده‌ی اصلی این است: به جای اینکه مقادیر ویژه‌ی یک ماتریس بسیار بزرگ A با ابعاد $n \times n$ را مستقیماً حساب کنیم، با ضرب‌های متوالی ماتریس در یک بردار $(v, Av, A^2v, \dots)$ یک زیرفضای کوچک‌تر به نام فضای کرایلف $\mathcal{K}_m$ می‌سازیم:

$$\mathcal{K}_m(A, v) = \text{span}\{v, Av, A^2v, \dots, A^{m-1}v\}.$$

لانتساش با استفاده از یک رابطه‌ی بازگشتی سه‌جمله‌ای یک پایه‌ی متعامد یکه برای این فضا می‌سازد. نتیجه‌ی این کار، تصویرکردن ماتریس غول‌پیکر A روی یک ماتریس بسیار کوچک‌تر به نام T_m (با ابعاد $m \times m$) است که ساختاری **سه‌قطری** دارد. مقادیر ویژه‌ی ماتریس کوچک T_m (که به آن‌ها مقادیر ریتز می‌گویند) تقریب بسیار خوبی برای مقادیر ویژه‌ی حده‌ی (بزرگ‌ترین و کوچک‌ترین‌های) ماتریس A هستند.

۲.۷ رابطه‌ی بازگشتی سه‌جمله‌ای

به دلیل تقارن A ، هر بردار پایه‌ی جدید فقط به دو بردار قبلی وابسته است؛ پس گرام-اشمیت به یک رابطه‌ی بازگشتی سه‌جمله‌ای ساده تبدیل می‌شود. کافی است با یک بردار یکه‌ی اولیه‌ی $q_1 = v / \|v\|$ شروع کنیم و در هر گام این چهار محاسبه را انجام دهیم:

۱. یک ضرب ماتریس-بردار و کم‌کردن سهم بردار قبلی: $w = Aq_j - \beta_{j-1}q_{j-1}$.

۲. درایه‌ی قطر اصلی: $\alpha_j = q_j^\top w$.

۳. حذف مؤلفه‌ی q_j از w : $w \leftarrow w - \alpha_j q_j$.

۴. درایه‌ی کنار قطر و بردار بعدی: $\beta_j = \|w\|_2$ و $q_{j+1} = w / \beta_j$.

(با قرارداد $\beta_0 = 0$ و $q_0 = 0$ ؛ در عمل گام ۳ را برای پایداری دوباره تکرار می‌کنیم.) با کنار هم گذاشتن بردارها به صورت ستون‌های $Q_m = [q_1 \dots q_m]$ ، ماتریس سه‌قطری حاصل چنین است:


$$T_m = Q_m^\top A Q_m = \begin{pmatrix} \alpha_1 & \beta_1 & & \\ \beta_1 & \alpha_2 & \beta_2 & \\ & \beta_2 & \ddots & \ddots \\ & & \ddots & \alpha_m \end{pmatrix}.$$

یعنی روی قطر اصلی α -ها و روی دو قطر کناری β -ها می‌نشینند. چون یافتن مقادیر ویژه‌ی یک ماتریس سه‌قطری ارزان است، این مقادیر (تقریب خوبی از مقادیر ویژه‌ی

(A) را حساب می‌کنیم و بردارهای ویژه‌ی A را هم از رابطه‌ی $x = Q_m y$ بازسازی می‌کنیم که در آن y بردار ویژه‌ی T_m است.

۳.۷ مزیت نسبت به روش‌های قبلی

- لانتساش به A تنها از راه Av دسترسی دارد و هیچ نیازی به ساختن، معکوس کردن یا تجزیه‌ی A ندارد. چون ماتریس W (و در نتیجه L_{sym}) در مسئله‌ی ما تُنک است، هر ضرب تنها $O(\text{nnz})$ هزینه دارد، که برای تصاویر بزرگ بسیار به‌صرفه است.
- برخلاف روش توان معکوس $+$ حذف که بردارها را یکی‌یکی پیدا می‌کند و خطای حذف در هر مرحله انباشته می‌شود، لانتساش چند بردار ویژه‌ی کرانی را هم‌زمان و با همگرایی سریع به دست می‌دهد.
- روش توانی در هر تکرار بردار قبلی را دور می‌اندازد و فقط با بردار جدید کار می‌کند؛ اما لانتساش با ساختن زیرفضای کرایلف اطلاعات همه‌ی ضرب‌های پیشین ($v, Av, A^2v, \dots$) را نگه می‌دارد و از ترکیب خطی آن‌ها برای تقریب بهتر بهره می‌برد؛ به همین دلیل همگرایی آن به‌مراتب سریع‌تر است.
- حافظه و محاسباتش با n به‌صورت خطی (با ضریب $n \ll m$) رشد می‌کند، در حالی‌که روش‌های متراکم $O(n^3)$ هستند.
- در حساب ممیز شناور، تعامد بردارهای q_j به‌مرور از بین می‌رود و مقادیر ویژه‌ی کاذب ظاهر می‌شوند؛ به همین دلیل از متعامدسازی مجدد (کامل یا گزینشی) استفاده می‌کنیم.
- چون در قطعه‌بندی به کوچک‌ترین مقادیر ویژه نیاز داریم، لانتساش را یا روی عملگر شیفت و معکوس $(\mu I - L_{\text{sym}})^{-1}$ اجرا می‌کنیم یا روی $2I - L_{\text{sym}}$ ؛ این دومی کوچک‌ترین مقادیر ویژه‌ی L_{sym} را به بزرگ‌ترین‌ها تبدیل می‌کند و لانتساش هم به بزرگ‌ترین‌ها سریع همگرا می‌شود.



قطعه‌بندی یک تصویر بزرگ با لانتساش روی ماتریس تُنک.